MPI
Message Passing Interface

Лекция 1

Что почитать

- Русский Internet ресурс
  (http://www.parallel.ru)
- Лекции Воеводина
  (http://parallel.ru/parallel/vvv/mpi.html)
- Стандарт MPI
  (http://www-unix.mcs.anl.gov/mpi/standard.html)
- Jan Forster “Designing and Building Parallel programs” (http://www-unix.mcs.anl.gov/dbpp/)
- Лекция Вильяма Гроффа
  (http://www-unix.mcs.anl.gov/mpi/tutorial/gropp/talk.html)

Существующие реализации MPI

- MPICH (http://www-unix.mcs.anl.gov/mpi/mpich)
- LAM (http://www.lam-mpi.org)
- WMPI (http://www.criticalsoftware.com/hpc)
- OpenMPI (http://www.open-mpi.org/)

- Intel cluster tools (http://www.intel.com/cd/software/products/asmo-na/eng/cluster/)
- IBM Parallel Operating Environment (http://publib.boulder.ibm.com/infocenter/clresctr/vxrx/index.jsp)
- SUN HPC cluster tools (http://www.sun.com/products/hpc/communitysource/)
- Scali (http://www.scali.com/)
- Microsoft Compute Cluster Server (http://windowshpc.net/default.aspx)

Задачи MPI как среды программирования.

- Обеспечить интерфейс передачи сообщений в условиях разделённой памяти.
- Возможность писать приложения для гетерогенной многопроцессорной среды.
- Прозрачный механизм запуска параллельного приложения основанный на SPMD модели.

Задачи MPI как среды программирования.

- Понятный для пользователя механизм запуска параллельного приложения основанный на SPMD модели.

- Сокрытие от пользователя MPI всех деталей реализации конкретной физической среды межпроцессорных взаимодействий.

Компоненты MPI

- mpirun - Запуск программ на выполнение.

  mpirun –np 12 prog param1 param2 …

- mpicc, mpif77,mpif90, mpiCC,mpicxx – компиляторы.

- Средства отладки и построения трасс сообщений. (Например jumpshot в MPICH)

Основные понятия MPI.

- Процесс (Нить)
- Коммуникатор и группы.
- Типы данных и манипуляции с данными (упаковка,распаковка и создание собственных типов.)
- Передача данных (блокирующая, не блокирующая,коллективные обмены данными.)
- Средства синхронизации.

Программа на MPI

- Программа распадается на набор процессов (нитей).
- Ветвление производится по вызову:

  MPI_Init(int **argc,char ***argv);
- Нить завершается по MPI_Finalize();
- Или завершается по MPI_Abort();

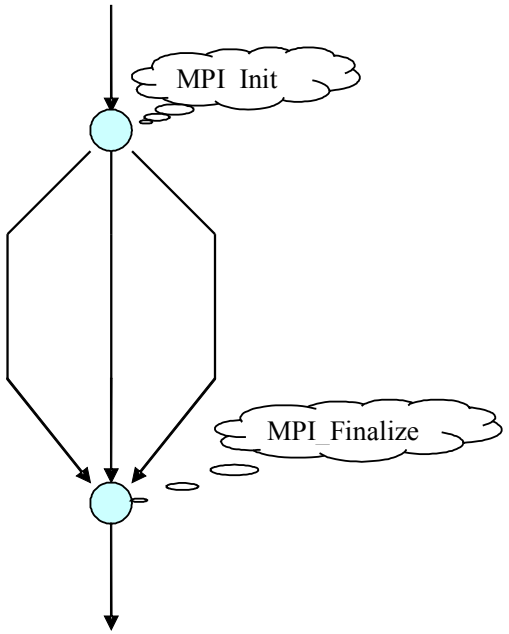

Процесс запуска MPI программы

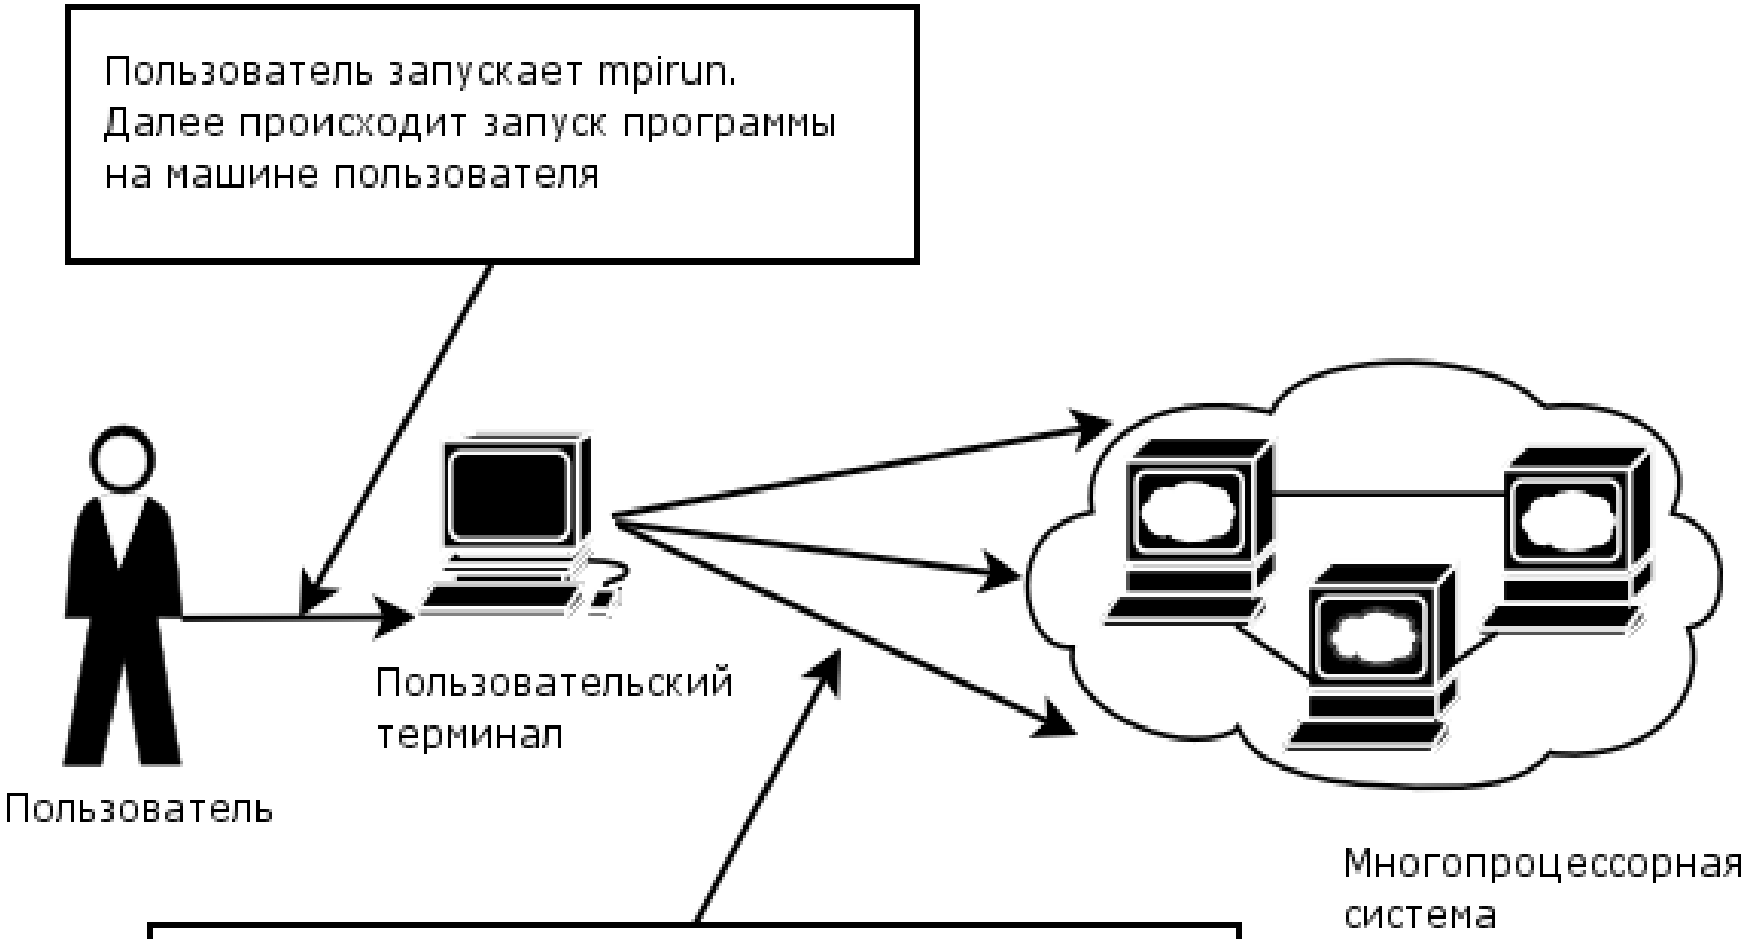

Ввод-вывод в MPI

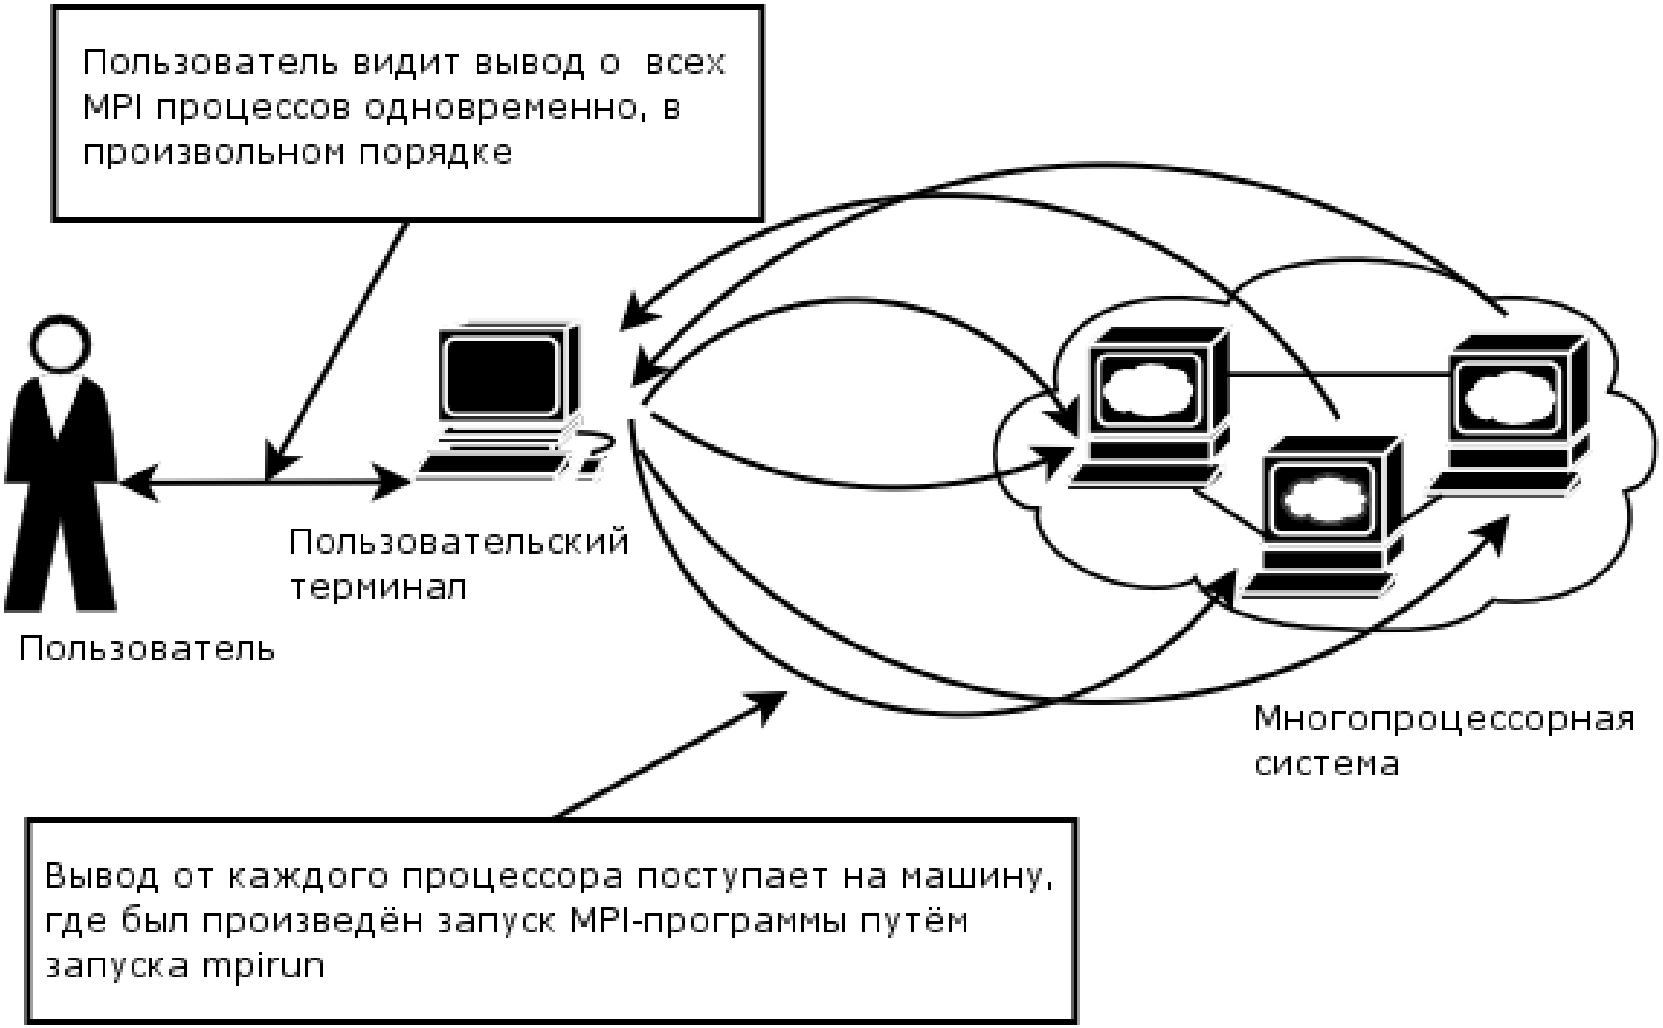

MPI_Finalize() и MPI_Abort()

- MPI_Finalize() – Завершает работу нити, освобождает процессор если он занят данной нитью, если вызван в управляющей нити, то блокирует нить и ждёт завершения остальных.

- MPI_Abort(comm,int status) – в случае вызова хотябы одной нитью, завершает все нити коммуникатора, где процесс операционной системы возвращает код завершения status.

Процессы

- Все нити изначально присоединены к коммуникатору MPI_COMM_WORLD
- Нить может выяснить число запущенных нитей при помощи функции MPI_Comm_size(MPI_COMM_WORLD,&size);
- Нить может выяснить свой порядковый номер MPI_Comm_rank(MPI_COMM_WORLD,&rank);
  - В MPI-1 число нитей строго фиксировано до момента запуска программы и в процессе не меняется. (В MPI-2 – это ограничение снято.)

Простейший пример программы на MPI

```
#include <mpi.h>
#include <stdio.h>

int main(int argc,char **argv)
{
 int size,rank;
 MPI_Init(&argc,&argv);
 MPI_Comm_size(MPI_COMM_WORLD,&size);
 MPI_Comm_rank(MPI_COMM_WORLD,&rank);

  printf("I am %d where processes %d. Hello
World!!!\n",rank,size);

MPI_Finalize();
return 0;
}
```

Простейший пример программы на MPI

```
program main
include 'mpif.h'
begin

        integer size, rank

        call MPI_INIT(ierr)
        call MPI_COMM_SIZE(MPI_COMM_WORLD,size,ierr)
        call MPI_COMM_RANK(MPI_COMM_WORLD,rank,ierr)

        print *, “I am “, rank,” where processes” ,size, ”. Hello World!!!”

        call MPI_FINALIZE();

end
```

Обмен данными

- Передача типа точка-точка (блокированая,неблокированная)
- Коллективные пересылки.
- Распределённые операции.

Блокированные обмены типа точка-точка.

- MPI_Send(buf,count,datatype,dest,tag,comm)
  Данная процедура блокирует вызвавший её процесс, до тех пор, пока данные не будут приняты с другой стороны.

buf – собственно передаваемые данные

count – число ячеек передаваемых данных.

datatype – тип передаваемых данных (MPI_INT к примеру.)

dest – порядковый для указанного коммуникатора номер нити. Туда данные будут переданы.

tag – Числовая метка сообщения.

comm – коммуникатор, через который происходит передача данных.

Блокированные обмены типа точка-точка.

- MPI_Recv(buf,count,datatype,dest,tag,comm,status)

  Блокирует вызвавший её процесс, пока данные от другого процесса не будут приняты целиком.

  Все параметры аналогичные MPI_Send но есть ещё status.

  Статус структура содержит tag полученного сообщения, номер пославшей нити, размер сообщения. Используется совместно с MPI_ANY_SOURCE и MPI_ANY_TAG

Режимы посылки сообщений

- ***MPI_Ssend*** – немедленная небуферизованная посылка сообщения.
- ***MPI_Bsend*** – буферизованная посылка сообщения.
- ***MPI_Rsend*** – посылка сообщения при условии наличия информации о том, что принимающая сторона уже вызвала MPI_Recv к этому моменту.

Проблема синхронизации

- Тупики
- Гонки
- Неэффективность.

Синхронизация

- MPI_Barrier(comm) – останавливает процесс до тех пор, пока все процессы присоединённые к коммуникатору не вызовут барьер.

Пример: уравнение теплопроводности.

Рассмотрим задачу:

$$u_t = a^2 \cdot \Delta u(x) + f(x,t) \qquad t \geq 0$$

$$u(x,t)\big|_{x \in G} = \varphi(t) \quad G = \overline{M} \setminus M$$ - граница области - M.

$$u(x,0) = \psi(x) \qquad x \in M$$

Пример: уравнение теплопроводности.

Сопоставим данной задаче разностную:

$$u(x_i, t_j + \Delta t) = \Delta t \cdot a^2 \cdot (u(x_{i-1}, t_j) - 2 * u(x_i, t_j) + u(x_{i+1}, t_j)) / \Delta x +$$
$$+ f(x_i, t_j) \cdot \Delta t + u(x_i, t_j).$$

Способ распараллеливания.

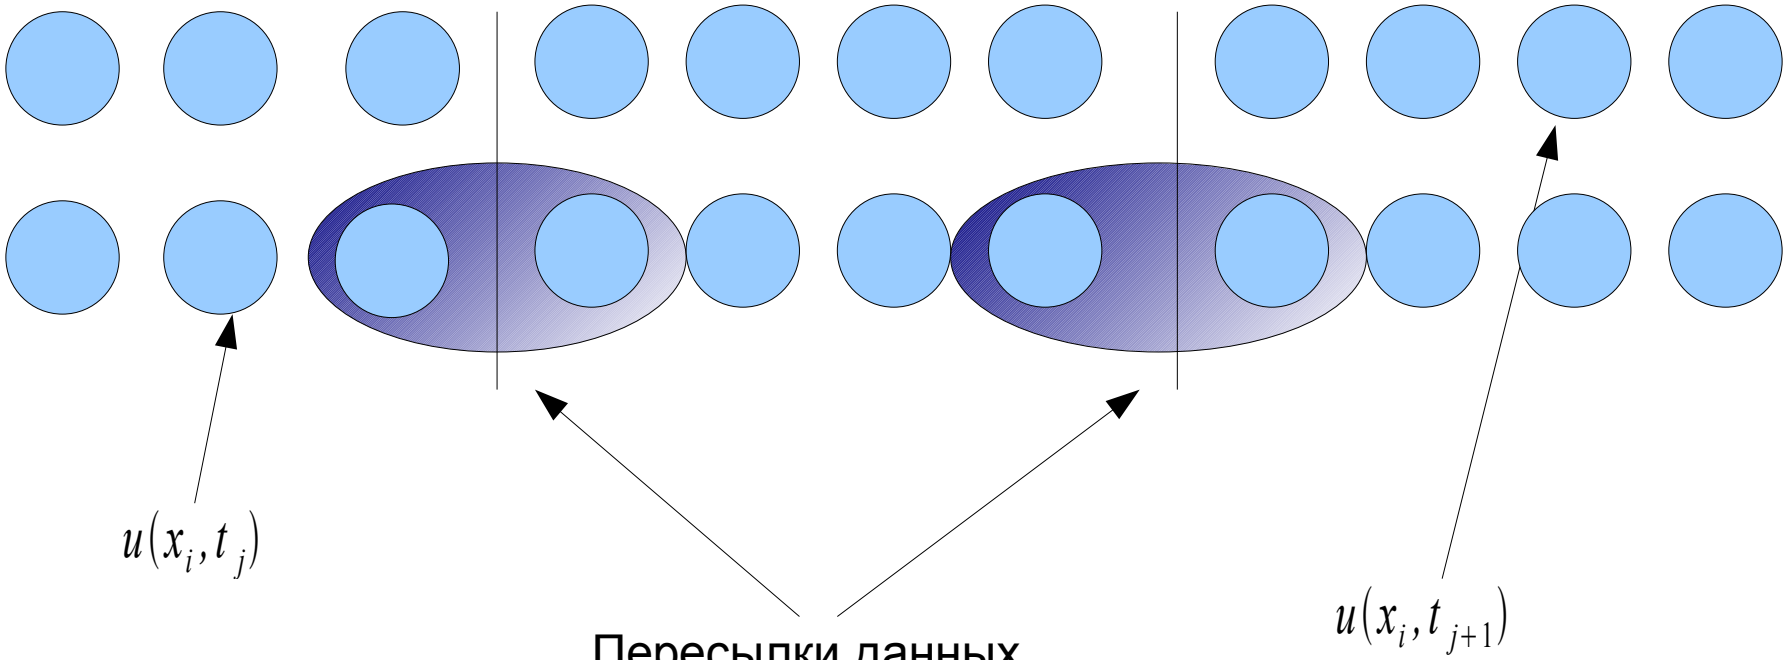

Уравнение теплопроводности (неработающий вариант.)

```
#include <mpi.h>
#include <stdio.h>

#define T 100
#define U 200
#define a 4

int main(int argc,char **argv)
{
 int comm_rank,comm_size;
 double u[T][U]; /* 200 points by X and 100 by T  and f=0 */
 int i,t;
 MPI_Status st;

 for(t=0;t<T;t++)
 {
  u[t][0]=1;
  u[t][U-1]=100;
 }

 for(i=1;i<U-1;i++)
 {
  u[0][i]=100/(double)(2*i);
 }

 MPI_Init(&argc,&argv);
 MPI_Comm_size(MPI_COMM_WORLD,&comm_size);
 MPI_Comm_rank(MPI_COMM_WORLD,&comm_rank);
```

Уравнение теплопроводности (неработающий вариант.)

```
for(t=0;t<T-1;t++)
{
 if((comm_rank!=comm_size-1)&&(comm_rank!=0))
 {
  MPI_Ssend(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,comm_rank-1,0,MPI_COMM_WORLD);
  MPI_Ssend(&u[t][(U/comm_size)*(comm_rank+1)],1,MPI_DOUBLE,comm_rank+1,1,MPI_COMM_WORLD);
  MPI_Recv(&u[t][(U/comm_size)*(comm_rank)-1],1,MPI_DOUBLE,comm_rank-1,1,MPI_COMM_WORLD,&st);
  MPI_Recv(&u[t][(U/comm_size)*(comm_rank+1)+1],1,MPI_DOUBLE,comm_rank+1,0,MPI_COMM_WORLD,&st);
 }
 if(comm_rank==0)
 {
  MPI_Ssend(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,1,1,MPI_COMM_WORLD);
  MPI_Recv(&u[t][(U/comm_size)*(comm_rank+1)+1],1,MPI_DOUBLE,1,0,MPI_COMM_WORLD,&st);
 }
 if(comm_rank==comm_size-1)
 {
  MPI_Ssend(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,comm_rank-1,0,MPI_COMM_WORLD);
  MPI_Recv(&u[t][(U/comm_size)*(comm_rank)-1],1,MPI_DOUBLE,comm_rank-1,1,MPI_COMM_WORLD,&st);
 }
```

Уравнение теплопроводности (неработающий вариант.)

```
if(comm_rank!=comm_size-1)
 {
  for(i=(U/comm_size)*(comm_rank);i<(U/comm_size)*(comm_rank+1);i++)
  {
   u[t+1][i]=a*a*(u[t][i-1]-2*u[t][i]+u[t][i+1])+u[t][i];
   printf("u[%d][%d]=%lf\n",t+1,i,u[t+1][i]);
  }
 }
 else
 {
  for(i=(U/comm_size)*(comm_rank-1);i<U;i++)
  {
   u[t+1][i]=a*a*(u[t][i-1]-2*u[t][i]+u[t][i+1])+u[t][i];
   printf("u[%d][%d]=%lf\n",t+1,i,u[t+1][i]);
  }
 }
} /* END FOR through T */


MPI_Finalize();
return 0;
}
```

Тупики (deadlocks)

- В первом случае никогда не вызовется MPI_Recv
- Во втором случае никогда не вызовется MPI_Send

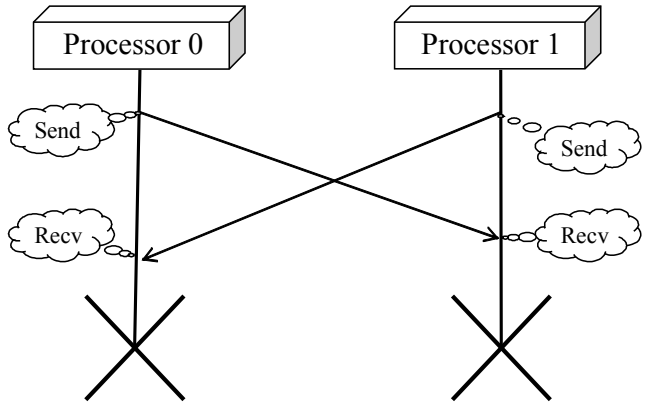

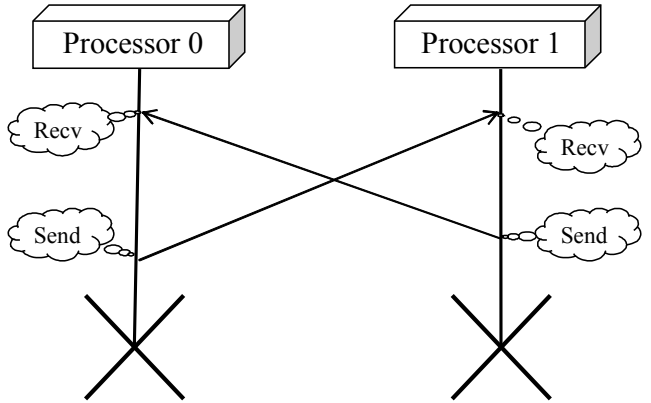

Уравнение теплопроводности (плохо работающий вариант.)

```
for(t=0;t<T-1;t++)
 {
  if(comm_rank==0)
  {
   MPI_Send(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,1,1,MPI_COMM_WORLD);
   MPI_Recv(&u[t][(U/comm_size)*(comm_rank+1)+1],1,MPI_DOUBLE,1,0,MPI_COMM_WORLD,&st);
  }
  if((comm_rank!=comm_size-1)&&(comm_rank!=0))
  {
   MPI_Recv(&u[t][(U/comm_size)*(comm_rank)-1],1,MPI_DOUBLE,comm_rank-1,1,MPI_COMM_WORLD,&st);
   MPI_Send(&u[t][(U/comm_size)*(comm_rank+1)],1,MPI_DOUBLE,comm_rank+1,1,MPI_COMM_WORLD);
   MPI_Recv(&u[t][(U/comm_size)*(comm_rank+1)+1],1,MPI_DOUBLE,comm_rank+1,0,MPI_COMM_WORLD,&st);
   MPI_Send(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,comm_rank-1,0,MPI_COMM_WORLD);

  }

  if(comm_rank==comm_size-1)
  {
   MPI_Recv(&u[t][(U/comm_size)*(comm_rank)-1],1,MPI_DOUBLE,comm_rank-1,1,MPI_COMM_WORLD,&st);
   MPI_Send(&u[t][(U/comm_size)*(comm_rank)],1,MPI_DOUBLE,comm_rank-1,0,MPI_COMM_WORLD);
  }
```

Пример с гонками.

```
If(comm_rank!=0)
 for(i=0;i<100;i++)
 {
   MPI_Send(&i,1,MPI_INT,0,0,MPI_COMM_WORLD);
 }

If(comm_rank==0)
{
 for(i=0;i<100*(comm_size-1);i++)
 {
  MPI_Recv(&res,1,MPI_INT,MPI_ANY_SOURCE,0,
                  MPI_COMM_WORLD,&st);
  printf("(%d,%d)\n",res,st.MPI_SOURCE);
 }
}
```

Приём данных неизвестного размера.

- MPI_Probe(source,tag,comm,status) – Блокирует процесс до тех пор, пока не будет возможно получить соответствующие данные с помощью MPI_Recv. Данная процедура заполняет status.

- MPI_Get_count(status,datatype,count) – в count выдаёт число элементов заданного типа данных в сообщении.

Пример приёма сообщений неизвестного размера.

```
#include <mpi.h>
#include <stdio.h>
int main(int argc, char **argv)
{
int size, rank;

int count;
MPI_Status status;
char *buf;

MPI_Init(&argc, &argv); /* Инициализируем библиотеку */
MPI_Comm_size(MPI_COMM_WORLD, &size); /* Узнаем количество задач в запущенном приложении... */
MPI_Comm_rank (MPI_COMM_WORLD, &rank); /* ...и свой собственный номер: от 0 до (size-1) */

if ((size > 1) && (rank == 0))
 {         /* задача с номером 0 отправляет сообщение*/
  MPI_Send(argv[0], strlen(argv[0])+1, MPI_CHAR, 1, 1, MPI_COMM_WORLD);
  printf("Sent to process 1: \"%s\"\n", argv[0]);
}
else if ((size > 1) && (rank == 1))
 { /* задача с номером 1 получает сообщение*/
  MPI_Probe(0, 1, MPI_COMM_WORLD, &status);
  MPI_Get_count(&status, MPI_CHAR, &count);
  buf = (char *) malloc(count * sizeof(char));
  MPI_Recv(buf, count, MPI_CHAR, 0, 1, MPI_COMM_WORLD, &status);
  printf("Received from process 0: \"%s\"\n", buf);
 }

MPI_Finalize(); /* Все задачи завершают выполнение */
 return 0;
}
```

Неблокированные обмены.

- На фоне приёма и передачи данных могут производится вычисления.
- MPI_Isend(buf, count, datatype, dest, msgtag, comm, request)
- MPI_Irecv(buf, count, datatype, dest, msgtag, comm, request) – нет статуса!
- В отличии от блокированного send появляется выходной параметр request – идентификатор посылки, по нему затем можно узнать состояние обмена данными. (Аналогично для MPI_Irecv)

Неблокированные обмены.

- MPI_Wait(request,status) Ждёт завершения одного обмена и инициализирует по окончанию статус.
- MPI_Waitall(count,requests,statuses) – аналогична MPI_Wait только сразу для count обменов.
- MPI_Waitany(count,requests,index,statuses) – в index собержится порядковый номер среди requests завершившегося обмена.

Неблокированные обмены.

- MPI_Test(request, flag,status) – В отличии от MPI_Wait не блокирует процесс, а возвращает 0 в случае, если обмен не завершился и 1 если завершился.
- MPI_Testany – аналогично MPI_Waitany
- MPI_Testall – аналогично MPI_Waitall
- MPI_Iprobe – Не блокирует процесс. Аналогично MPI_Probe заполняет status, но как и в случае с MPI_Test в flag возвращается 1 если данные готовы к приёму с помощью MPI_Recv.

Коллективные обмены

- MPI_Bcast(buf,count,datatype,source,comm) – распространяет буфер по всем процессам присоединённым к коммуникатору.
- MPI_Gather(sbuf,scount,stype,rbuf,rcount, rtype, dest,comm) - собирает значения sbuf с процессов коммуникатора в rbuf на процессе с номером dest.
- MPI_Scatter – действие противоположное к MPI_Gather содержимое sbuf с source процесса по другим процессам.
- MPI_Alltoall – действие аналогично транспонированию матрицы.

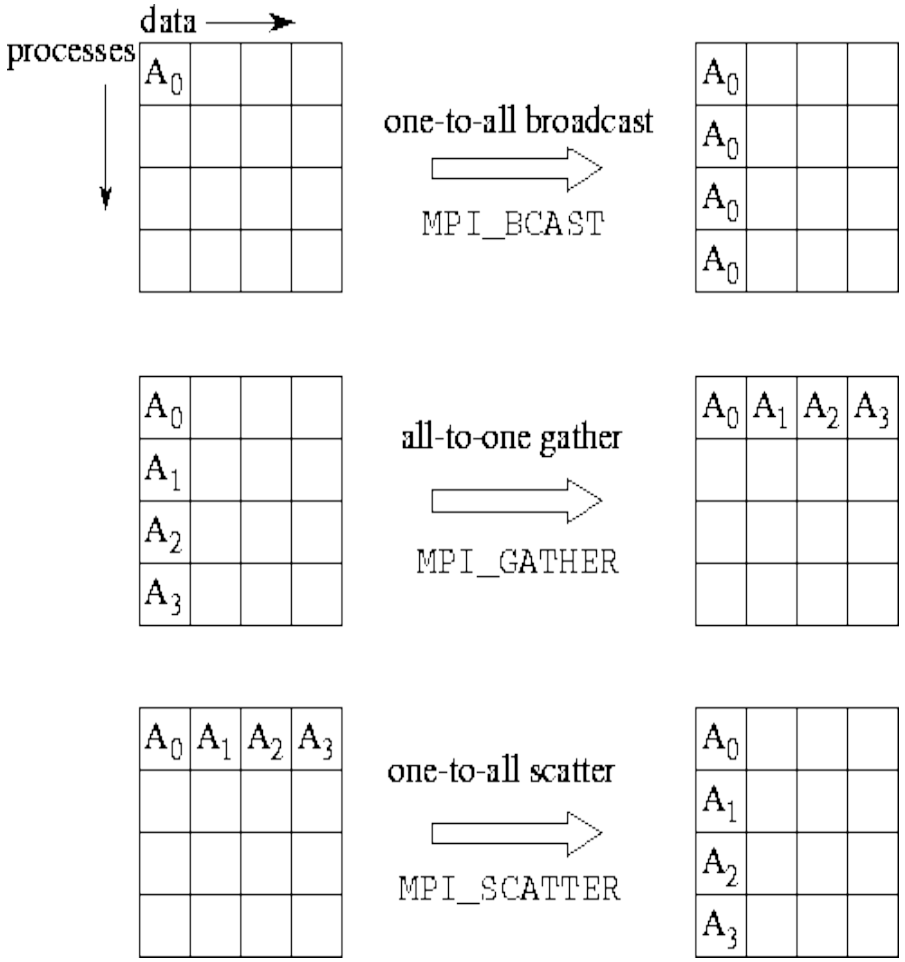

Распределённые операции.

- MPI_Reduce(sbuf,rbuf,count, datatype,op,root,comm) – Выполняет операцию op над соответствующими элементами каждого процесса, и результат запишет в процесс с номером root.
- MPI_Allreduce(sbuf,rbuf,coun t,datatype,op,comm) – делает тоже самое, но результат заносит во все процессы сразу.